

**UNIVERSIDAD NACIONAL AUTÓNOMA DE
MÉXICO**

Facultad de Estudios Superiores Acatlán

Procesos Estocásticos I

Semestre 2026-2

Sonny Medina (Draft)

16 de febrero de 2026

Índice general

Capítulo 1

Modelos Markovianos en Tiempo Discreto

La teoría de procesos estocásticos tuvo sus orígenes en los trabajos de Andréi Márkov a principios del siglo XX. Márkov, discípulo de Pafnuty Chebyshev al igual que Andréi Kolmogorov, estudió sucesiones de variables aleatorias que satisficieran una propiedad especial: la dependencia entre observaciones sucesivas. Aunque las contribuciones de Márkov no fueron tan formales como las posteriores de Kolmogorov, quien desarrolló la teoría axiomática de la probabilidad, Márkov es considerado el precursor de la teoría moderna de procesos estocásticos. En sus trabajos iniciales, Márkov se enfocó principalmente en procesos a tiempo discreto con un enfoque probabilístico. Con el desarrollo de la teoría, especialmente tras las contribuciones de Kolmogorov, la disciplina se formalizó considerablemente e incorporó tanto procesos a tiempo discreto como continuo, ampliando su alcance hacia aplicaciones contemporáneas en física estadística, finanzas matemáticas, biología, ingeniería y ciencias de la computación. En la actualidad, los procesos estocásticos constituyen una herramienta fundamental para modelar sistemas dinámicos bajo incertidumbre, con aplicaciones que van desde la modelación de mercados financieros y sistemas de colas, hasta algoritmos de aprendizaje automático, métodos de Monte Carlo vía cadenas de Markov y el análisis de datos temporales en contextos científicos e industriales.

1.1. Definición de Proceso Estocástico

Definición 1.1. Un **proceso estocástico** es una colección de variables aleatorias $\{X_t : t \in T\}$ definidas sobre un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, donde:

- T es el **índice temporal**, que puede ser discreto ($T = \mathbb{N}$) o continuo ($T = \mathbb{R}^+$). Asumiremos que ambos conjuntos contienen al cero.
- X_t representa el estado del sistema en el tiempo t .

Un proceso estocástico es **discreto** si T es un conjunto discreto, y **continuo** si T es un conjunto continuo.

Interpretación como función

Un proceso estocástico puede interpretarse como una función

$$X : T \times \Omega \rightarrow S$$

tal que a cada pareja $(t, \omega) \in T \times \Omega$ se le asocia el estado $X(t, \omega) \in S$. Para cada tiempo $t \in T$ fijo, la función $\omega \mapsto X(t, \omega)$ es una variable aleatoria. Por el contrario, para cada resultado $\omega \in \Omega$ fijo, la función $t \mapsto X(t, \omega)$ se llama una **trayectoria** o **realización** del proceso, y representa la evolución temporal del sistema bajo el escenario particular ω .

EJEMPLOS

1.2. Espacio de Estados

El **espacio de estados** de un proceso estocástico es el conjunto S de todos los valores posibles que las variables aleatorias X_t pueden tomar. Se requiere que S sea equipado con una σ -álgebra apropiada para poder hablar de eventos relacionados con los valores del proceso. Consideraremos principalmente espacios de estados discretos (subconjuntos de $\mathbb{Z}$) o continuos (subconjuntos de $\mathbb{R}$, $\mathbb{R}^d$, etc.). Por ejemplo:

- Si $S = \{0, 1\}$, el proceso es binario.
- Si $S = \mathbb{R}$, el proceso tiene un espacio de estados continuo.
- Si $S = \mathbb{Z}$, el proceso tiene un espacio de estados discreto infinito.
- Si $S = \mathbb{R}^d$ para $d \geq 2$, el espacio de estados es multidimensional.

Ejemplo 1.1 (1). Sucesión de resultados de un dado. Considere un dado justo. El espacio parametral es $T = \mathbb{N}$, ya que observamos los resultados en pasos discretos (cada lanzamiento). El espacio de estados es $S = \{1, 2, 3, 4, 5, 6\}$ y supondremos que s.p.g. $P(X_0 = 6) = 1$. Ejemplos de probabilidades de interés incluyen:

- $\mathbb{P}(X_3 = 6)$: Probabilidad de obtener un 6 en el tercer lanzamiento.
- $\mathbb{P}(\text{al menos un 6 en 5 lanzamientos})$.
- $\mathbb{P}(\text{El primer 6 sale en el lanzamiento } k)$.
- Probabilidades condicionales como $\mathbb{P}(X_4 = 5 \mid X_3 = 2)$.

Un proceso estocástico se llama cadena cuando es un proceso indexado en tiempo discreto, con espacio de estados numerable. Si dibujamos los posibles estados como nodos en un grafo, y las transiciones entre estados como aristas dirigidas obtenemos una representación visual útil para analizar el comportamiento del proceso.

1.3. Caminata Aleatoria

Un ejemplo fundamental en la teoría de procesos estocásticos es la **caminata aleatoria**. Sea $\{Y_i : i \in \mathbb{N}\}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas (i.i.d.), todas definidas sobre el mismo espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, que toman valores en $S_Y \subseteq \mathbb{R}$. Denotamos por μ_Y la distribución común de las variables Y_i . Consideremos la sucesión de sumas parciales:

$$X_n = \sum_{i=1}^n Y_i, \quad n \in \mathbb{N}, \quad \text{con } X_0 = 0.$$

Este proceso se llama **caminata aleatoria** o **proceso de suma acumulada**, y es un proceso a tiempo discreto con espacio de estados $S \subseteq \mathbb{R}$ (típicamente $S = \mathbb{Z}$ o $S = \mathbb{R}$ dependiendo de la distribución de Y_i).

Proposición 1.1. *Para una caminata aleatoria $X_n = \sum_{i=1}^n Y_i$ donde los Y_i son i.i.d.:*

- *La distribución de X_n es la convolución de n copias de μ_Y .*
- *Para $n \geq 1$, se tiene $X_n = X_{n-1} + Y_n$, por lo que la probabilidad de transición depende únicamente de la distribución de Y_i .*

Ejemplo 1.2 (2). **Caminata aleatoria simétrica en $\mathbb{Z}$.** Sea Y_i con distribución $\mathbb{P}(Y_i = 1) = \mathbb{P}(Y_i = -1) = \frac{1}{2}$. El proceso $X_n = \sum_{i=1}^n Y_i$ es una caminata aleatoria simétrica donde en cada paso el proceso se mueve una unidad hacia la derecha o hacia la izquierda con igual probabilidad. Algunas probabilidades de interés:

- $\mathbb{P}(X_1 = 1) = \frac{1}{2}$ y $\mathbb{P}(X_1 = -1) = \frac{1}{2}$.
- $\mathbb{P}(X_2 = 0) = \mathbb{P}(Y_1 = 1, Y_2 = -1) + \mathbb{P}(Y_1 = -1, Y_2 = 1) = \frac{1}{4} + \frac{1}{4} = \frac{1}{2}$.
- $\mathbb{P}(X_2 = 2) = \mathbb{P}(Y_1 = 1, Y_2 = 1) = \frac{1}{4}$.
- $\mathbb{P}(X_3 = 0)$: Es necesario un número par de pasos $+1$ y un número par de pasos -1 . Esto es imposible en 3 pasos, por lo que esta probabilidad es 0.

Ejemplo 1.3 (3). **Caminata aleatoria de Pólya.** Consideremos Y_i con distribución $\mathbb{P}(Y_i = k) = p^k(1-p)^{1-k}$ para $k \in \{0, 1\}$, donde $0 < p < 1$. El proceso $X_n = \sum_{i=1}^n Y_i$ cuenta el número de “éxitos” hasta el tiempo n , y representa el número de caras en n lanzamientos de una moneda sesgada. Este tipo de caminata aleatoria tiene aplicaciones en economía, biología y otras áreas.

1.4. Distribución Inicial y Matriz de Transición

Distribución inicial. La distribución inicial (o distribución de probabilidad inicial) de un proceso estocástico describe la ley de probabilidad del estado del sistema en el tiempo inicial. Para un proceso con espacio de estados S , se define como:

$$\pi = (\pi_i)_{i \in S}, \quad \text{donde } \pi_i = \mathbb{P}(X_0 = i) \geq 0, \quad \sum_{i \in S} \pi_i = 1.$$

En el caso de espacios de estados infinitos, la distribución inicial es una medida de probabilidad sobre S .

Probabilidades de transición. Para procesos a tiempo discreto, la **probabilidad de transición** de un paso describe la probabilidad de pasar de un estado i al estado j entre tiempo n y $n + 1$:

$$p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i), \quad \forall i, j \in S.$$

Cuando el espacio de estados es finito, estas probabilidades pueden organizarse en una **matriz de transición**:

$$P = (p_{ij})_{i,j \in S},$$

que es una matriz cuadrada cuyas entradas satisfacen propiedades específicas.

Proposición 1.2. Sea $P = (p_{ij})$ la matriz de probabilidades de transición de un paso para un proceso estocástico con espacio de estados finito $S = \{1, 2, \dots, m\}$. Entonces:

1. $p_{ij} \geq 0$ para todos $i, j \in S$.
2. $\sum_{j=1}^m p_{ij} = 1$ para todo $i \in S$ (cada fila suma 1).
3. P es una **matriz estocástica**.

Ejemplo 1.4 (4). Movilidad social y clases socioeconómicas. Considere una población clasificada en tres clases: baja (B), media (M) y alta (A). Sea X_n la clase socioeconómica del primogénito de una familia en la generación n . El espacio de estados es $S = \{B, M, A\}$ y el espacio parametral es $T = \mathbb{N}$.

Suponga que en el momento actual ($n = 0$), la distribución inicial es:

$$\pi_B = 0,5, \quad \pi_M = 0,3, \quad \pi_A = 0,2.$$

Esto significa que el 50 % de la población pertenece a la clase baja, el 30 % a la clase media y el 20 % a la clase alta. Una pregunta natural es: ¿Cuál es la probabilidad de que el nieto de una persona de clase baja pertenezca a la clase alta? Para responder esto necesitamos conocer las probabilidades de transición $p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i)$ para cada par de clases (i, j) .

Ejemplo 1.5 (5). Dinero en la cartera. Sea X_n la cantidad de dinero (en pesos) en nuestra cartera al final del día n . El espacio de estados es $S = \mathbb{R}_0^+$ (números reales no negativos). El espacio parametral es $T = \mathbb{N}$ (días). La distribución inicial X_0 depende de cuánto dinero teníamos al inicio, y las probabilidades de transición modelan cómo cambia nuestro saldo diariamente en función de nuestros gastos e ingresos, que pueden ser aleatorios.

Ejemplo 1.6 (6). Precio de una acción en la bolsa. Sea X_n el precio de una acción particular al cierre del día n . El espacio parametral es $T = \mathbb{N}$ (días de operación bursátil) y el espacio de estados es $S = \mathbb{R}^+$ (precios positivos). La distribución inicial depende del precio de cierre inicial de la acción. Las probabilidades de transición $\mathbb{P}(X_{n+1} \in [a, b] \mid X_n = x)$ modelan cómo evoluciona el precio día a día en respuesta a condiciones de mercado, y son un objeto central de estudio en matemática financiera.

Ejemplo 1.7 (7). Temperatura ambiente cada hora. Sea X_t la temperatura ambiente (en grados Celsius) registrada cada hora t durante un periodo de tiempo. Aquí, $T = \mathbb{N}$ (horas) y $S = \mathbb{R}$ (cualquier temperatura es posible en principio). La distribución inicial X_0 depende de la temperatura al momento inicial, y las probabilidades de transición reflejan patrones de cambio de temperatura entre horas consecutivas, que dependen de factores como la hora del día, la estación del año, y otras condiciones meteorológicas.

Ejemplo 1.8 (8). Deciles de ingresos. Sea X_n el decil de ingresos al que pertenece el primogénito de una familia en la generación n , donde los deciles son $S = \{D_1, D_2, \dots, D_{10}\}$ con D_1 siendo el 10 % más pobre y D_{10} el 10 % más rico. El espacio parametral es $T = \mathbb{N}$ (generaciones). La distribución inicial $(\pi_{D_1}, \dots, \pi_{D_{10}})$ representa la proporción de la población en cada decil. Las probabilidades de transición $p_{ij} = \mathbb{P}(X_{n+1} = D_j \mid X_n = D_i)$ describen la movilidad socioeconómica entre generaciones.

Ejemplo 1.9 (9). Estatura de una persona en el tiempo. Sea X_n la estatura de una persona (en centímetros) medida al final del año n . Aquí, $T = \mathbb{N}$ (años de vida) y $S = \mathbb{R}^+$ (estaturas positivas). La distribución inicial depende de la estatura al nacimiento. Las probabilidades de transición son determinísticas en el caso del crecimiento infantil (la estatura tiende a aumentar de manera predecible años a años durante la infancia), pero pueden incluir variabilidad en períodos posteriores.

Ejemplo 1.10 (10). Población de una especie. Sea X_n la cantidad total de individuos de una especie particular en una región al tiempo n . El espacio de estados es $S = \mathbb{Z}_{\geq 0}$ (números enteros no negativos), el espacio parametral es $T = \mathbb{N}$ (periodos de tiempo, p. ej., años), y la distribución inicial es el tamaño de la población inicial. Las probabilidades de transición dependen de tasas de natalidad, mortalidad, inmigración y emigración, que pueden ser determinísticas o estocásticas.

Ejemplo 1.11 (11). Movimiento de una partícula en un fluido. Sea $\mathbf{X}_t = (X_t, Y_t, Z_t) \in \mathbb{R}^3$ la posición de una partícula suspendida en un fluido al tiempo t (movimiento browniano). El espacio de estados es $S = \mathbb{R}^3$. Esta es una descripción clásica del movimiento aleatorio de partículas coloidales, estudiado por primera vez por Robert Brown. El espacio parametral puede ser discreto (si observamos la posición en intervalos regulares) o continuo (si consideramos la trayectoria continua de la partícula).

Observación 1.1. La distribución inicial y las probabilidades de transición determinan completamente la evolución probabilística de un proceso estocástico a tiempo discreto. Para un proceso con espacio de estados finito, la matriz de transición es una herramienta algebraica fundamental para estudiar el comportamiento a largo plazo del proceso.

La ruina del jugador

Consideremos uno de los problemas más antiguos e importantes de la teoría de procesos estocásticos: *el problema de la ruina del jugador*. Este problema ilustra cómo las probabilidades de transición pueden usarse para resolver preguntas fundamentales sobre la evolución de un proceso.

Planteamiento del problema. Un jugador inicia con una fortuna de k dólares. En cada ronda de juego:

- Con probabilidad p , el jugador gana \$1 (su fortuna aumenta a $k + 1$).
- Con probabilidad $q = 1 - p$, el jugador pierde \$1 (su fortuna disminuye a $k - 1$).

El juego continúa hasta que el jugador se arruina (fortuna = \$0) o alcanza una fortuna objetivo de \$N. Sea X_n la fortuna del jugador después de n rondas, donde $X_0 = k$. El espacio de estados es $S = \{0, 1, 2, \dots, N\}$, siendo 0 y N *estados absorbentes* (el juego termina cuando se alcanzan).

Las probabilidades de transición de un paso son:

$$p_{i,i+1} = p, \quad p_{i,i-1} = q, \quad \text{para } i \in \{1, 2, \dots, N-1\},$$

y $p_{0,0} = 1, p_{N,N} = 1$ (los estados absorbentes permanecen absorbentes).

Objetivo. Calcular $P_k := \mathbb{P}(\text{el jugador alcanza } \$N \mid X_0 = k)$, es decir, la probabilidad de que el jugador gane alcanzando la fortuna objetivo antes de arruinarse.

Solución mediante ecuaciones de recurrencia.

Razonemos de manera intuitiva. Si el jugador se encuentra en la fortuna k (con $0 < k < N$), en la siguiente ronda ocurre uno de dos eventos:

1. Con probabilidad p , el jugador gana \$1 y su fortuna pasa a $k + 1$.
2. Con probabilidad q , el jugador pierde \$1 y su fortuna pasa a $k - 1$.

Por lo tanto, la probabilidad de que el jugador eventualmente alcance \$N partiendo de k depende de lo que suceda en la próxima ronda. Podemos escribir:

$$P_k = p \cdot P_{k+1} + q \cdot P_{k-1}, \quad \text{para } 0 < k < N.$$

Con condiciones de frontera:

$$P_0 = 0 \quad (\text{si el jugador está arruinado, no puede ganar}),$$

$$P_N = 1 \quad (\text{si el jugador alcanza la fortuna objetivo, ha ganado}).$$

Esta es una ecuación de recurrencia lineal homogénea de segundo orden. Su solución depende del valor de p .

Caso 1: Juego justo ($p = q = \frac{1}{2}$).

Si $p = \frac{1}{2}$, la ecuación se convierte en:

$$P_k = \frac{1}{2}P_{k+1} + \frac{1}{2}P_{k-1},$$

que puede reescribirse como:

$$P_{k+1} - P_k = P_k - P_{k-1}.$$

Esto significa que las diferencias consecutivas son constantes. Por lo tanto, P_k es una función lineal de k :

$$P_k = a + bk$$

para algunas constantes a y b . Aplicando las condiciones de frontera:

$$P_0 = a = 0 \implies a = 0,$$

$$P_N = b \cdot N = 1 \implies b = \frac{1}{N}.$$

Por lo tanto:

$$P_k = \frac{k}{N} \quad (\text{para } p = \frac{1}{2}).$$

Esta es una conclusión importante: *en un juego justo, la probabilidad de ganar es proporcional a la fortuna inicial.*

Caso 2: Juego sesgado ($p \neq \frac{1}{2}$).

Cuando $p \neq q$, buscamos soluciones de la forma $P_k = r^k$. Sustituyendo en la ecuación de recurrencia:

$$r^k = p \cdot r^{k+1} + q \cdot r^{k-1}.$$

Dividiendo por r^{k-1} :

$$r = p \cdot r^2 + q,$$

o equivalentemente:

$$pr^2 - r + q = 0.$$

Las soluciones son:

$$r = \frac{1 \pm \sqrt{1 - 4pq}}{2p} = \frac{1 \pm \sqrt{(1 - 2p)^2}}{2p} = \frac{1 \pm |1 - 2p|}{2p}.$$

Como $p + q = 1$, tenemos $1 - 4pq = (p - q)^2 = (1 - 2p)^2$, por lo que:

$$r_1 = 1 \quad \text{y} \quad r_2 = \frac{q}{p}.$$

La solución general es:

$$P_k = A + B \left(\frac{q}{p} \right)^k$$

para constantes A y B . Aplicando las condiciones de frontera:

$$P_0 = A + B = 0 \implies B = -A,$$

$$P_N = A + B \left(\frac{q}{p} \right)^N = A \left(1 - \left(\frac{q}{p} \right)^N \right) = 1.$$

Despejando A :

$$A = \frac{1}{1 - (q/p)^N}.$$

Por lo tanto:

$$P_k = \frac{1 - (q/p)^k}{1 - (q/p)^N} \quad (\text{para } p \neq \frac{1}{2}).$$

Nótese que esta fórmula recupera el resultado del caso justo cuando $p = \frac{1}{2}$ (tomando el límite adecuado).

Interpretación de los resultados.

1. **Cuando $p > \frac{1}{2}$ (juego favorable).** Tenemos $q/p < 1$, por lo que $(q/p)^k \rightarrow 0$ cuando $k \rightarrow \infty$. Para un jugador con fortuna inicial k pequeña comparada con N , la probabilidad $P_k \approx 1 - (q/p)^k$ es cercana a 1. Esto indica que un jugador con ventaja tiene una alta probabilidad de ganar, especialmente si su objetivo es modesto.
2. **Cuando $p < \frac{1}{2}$ (juego desfavorable).** Tenemos $q/p > 1$, por lo que $(q/p)^k$ crece exponencialmente con k . Incluso si el jugador comienza con una buena fortuna inicial, la probabilidad de ganar disminuye exponencialmente. Para un jugador con $p < \frac{1}{2}$ y en contra de un oponente con una fortuna mucho mayor (N muy grande), la ruina es prácticamente segura.
3. **El caso justo.** Cuando $p = \frac{1}{2}$, la probabilidad de ganar es simplemente k/N , una relación lineal. Un jugador con fortuna k y objetivo N tiene una probabilidad de éxito igual a la proporción de su fortuna inicial respecto al capital total en juego.

Observación fundamental. Este problema demuestra la potencia de analizar procesos estocásticos a través de sus probabilidades de transición. Sin invocar teorías sofisticadas, simplemente planteando ecuaciones de recurrencia basadas en cómo el proceso evoluciona en un paso, hemos obtenido resultados exactos y muy interpretables. Esta es la esencia del enfoque mediante cadenas de Markov: comprender el comportamiento global del sistema a partir del conocimiento local de cómo transiciona entre estados adyacentes.

1.5. Cadenas de Markov

Un **proceso de Markov** es un proceso estocástico que satisface una propiedad especial de “falta de memoria”: el futuro del proceso, dado el estado presente, es independiente del pasado. Más formalmente:

Definición 1.2. Decimos que un proceso estocástico $\{X_n : n \in \mathbb{N}\}$ es un **proceso de Markov** si para todos $n \in \mathbb{N}$ y todos los estados $i_0, i_1, \dots, i_n, j \in S$:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i_n),$$

siempre que las probabilidades condicionales estén bien definidas.

Una **cadena de Markov** es un proceso de Markov a tiempo discreto con espacio de estados discreto.

Definición 1.3. Una **cadena de Markov homogénea** es una cadena de Markov donde las probabilidades de transición no dependen del tiempo n , es decir, $\mathbb{P}(X_{n+1} = j \mid X_n = i)$ es la misma para todo $n \geq 0$.

Observación 1.2. A menos que se indique lo contrario, en este curso supondremos que todas nuestras cadenas de Markov son homogéneas. Esta hipótesis simplifica significativamente el análisis matemático y es apropiada para muchas aplicaciones prácticas.

Observación 1.3. La distribución de una cadena de Markov homogénea depende únicamente de la distribución inicial y de las probabilidades de transición, es decir, de la pareja (π, P) .

Demostremos que la caminata aleatoria $\{X_n : n \in \mathbb{N}\}$ definida por $X_n = \sum_{i=1}^n Y_i$ (donde los Y_i son i.i.d. con distribución en $S_Y \subseteq \mathbb{R}$) es una cadena de Markov homogénea.

Proposición 1.3. *La caminata aleatoria $X_n = \sum_{i=1}^n Y_i$ con $X_0 = 0$ es una cadena de Markov homogénea cuando los Y_i son independientes e idénticamente distribuidas.*

Demostración. Demostramos dos cosas: primero que es una cadena de Markov, y luego que es homogénea.

Parte 1: Propiedad de Markov.

Sea $n \in \mathbb{N}$ y sean $i_0, i_1, \dots, i_n, j$ valores específicos en el espacio de estados. Queremos mostrar que:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i_n).$$

Por definición, $X_{n+1} = X_n + Y_{n+1}$. Dado que $X_n = i_n$, tenemos:

$$X_{n+1} = j \iff Y_{n+1} = j - i_n.$$

Por lo tanto:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(Y_{n+1} = j - i_n \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0).$$

Ahora bien, la variable aleatoria Y_{n+1} es independiente de todas las variables $Y_1, Y_2, \dots, Y_n$ por la hipótesis de independencia. Puesto que $X_0, X_1, \dots, X_n$ son funciones únicamente de $Y_1, Y_2, \dots, Y_n$, podemos concluir que Y_{n+1} es independiente de $(X_0, X_1, \dots, X_n)$. En particular:

$$\mathbb{P}(Y_{n+1} = j - i_n \mid X_n = i_n, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(Y_{n+1} = j - i_n).$$

Asimismo:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i_n) = \mathbb{P}(Y_{n+1} = j - i_n \mid X_n = i_n) = \mathbb{P}(Y_{n+1} = j - i_n).$$

Por lo tanto, se cumple la igualdad requerida, y $\{X_n\}$ es una cadena de Markov.

Parte 2: Homogeneidad.

Para demostrar que la cadena es homogénea, debemos verificar que la probabilidad de transición $p_{ij}^{[n]} := \mathbb{P}(X_{n+1} = j \mid X_n = i)$ no depende de n .

Para cualquier n , condicionando en $X_n = i$:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i) = \mathbb{P}(X_n + Y_{n+1} = j \mid X_n = i) = \mathbb{P}(Y_{n+1} = j - i \mid X_n = i).$$

Como Y_{n+1} es independiente de X_n :

$$\mathbb{P}(Y_{n+1} = j - i \mid X_n = i) = \mathbb{P}(Y_{n+1} = j - i).$$

Dado que todos los Y_i tienen la misma distribución, la probabilidad $\mathbb{P}(Y_{n+1} = j - i)$ es idéntica para cualquier n . Por lo tanto:

$$p_{ij} := \mathbb{P}(X_{n+1} = j \mid X_n = i) = \mathbb{P}(Y_1 = j - i)$$

no depende de n , lo que demuestra que la cadena es homogénea. □

Observación 1.4. Si considerásemos un proceso estocástico $\{Z_n : n \in \mathbb{N}\}$ donde cada Z_n es una variable aleatoria independiente, entonces el proceso sería trivialmente una cadena de Markov homogénea: la probabilidad de transición sería:

$$\mathbb{P}(Z_{n+1} = j \mid Z_n = i) = \mathbb{P}(Z_{n+1} = j),$$

que no depende del estado actual i . De hecho, para procesos con variables completamente independientes, la propiedad de Markov es automática porque el futuro es independiente de todo el pasado, incluyendo el presente. La especificidad de las cadenas de Markov reside en permitir dependencia entre variables aleatorias sucesivas (a través de las probabilidades de transición) mientras se mantiene la ausencia de memoria más allá del estado presente.

Ejemplos de cadenas de Markov con matriz de transición explícita

Ejemplo 1.12 (12). *Cadena de Markov con matriz de transición finita.* Consideremos una cadena de Markov con espacio de estados $S = \{1, 2, 3\}$ y matriz de transición:

$$P = \begin{pmatrix} 0,5 & 0,3 & 0,2 \\ 0,1 & 0,6 & 0,3 \\ 0,2 & 0,2 & 0,6 \end{pmatrix},$$

donde P_{ij} representa la probabilidad $p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i)$. Por ejemplo:

- $p_{1,1} = 0,5$: Si el proceso está en estado 1, permanece en estado 1 con probabilidad 0.5.
- $p_{1,2} = 0,3$: Si el proceso está en estado 1, transiciona a estado 2 con probabilidad 0.3.
- $p_{2,3} = 0,3$: Si el proceso está en estado 2, transiciona a estado 3 con probabilidad 0.3.

Cada fila de la matriz suma 1, como corresponde a una matriz estocástica. Supongamos una distribución inicial $\pi = (0,4, 0,3, 0,3)$, lo que significa:

$$\mathbb{P}(X_0 = 1) = 0,4, \quad \mathbb{P}(X_0 = 2) = 0,3, \quad \mathbb{P}(X_0 = 3) = 0,3.$$

A partir de esta distribución inicial y la matriz de transición, podemos calcular la distribución de probabilidades en tiempos posteriores. Por ejemplo, la distribución en tiempo 1 es:

$$\pi^{(1)} = \pi \cdot P = (0,4, 0,3, 0,3) \cdot P.$$

Calculando:

$$\pi_1^{(1)} = 0,4 \cdot 0,5 + 0,3 \cdot 0,1 + 0,3 \cdot 0,2 = 0,2 + 0,03 + 0,06 = 0,29,$$

$$\pi_2^{(1)} = 0,4 \cdot 0,3 + 0,3 \cdot 0,6 + 0,3 \cdot 0,2 = 0,12 + 0,18 + 0,06 = 0,36,$$

$$\pi_3^{(1)} = 0,4 \cdot 0,2 + 0,3 \cdot 0,3 + 0,3 \cdot 0,6 = 0,08 + 0,09 + 0,18 = 0,35.$$

Por lo tanto, $\pi^{(1)} = (0,29, 0,36, 0,35)$.

Ejemplo 1.13 (13). *La Urna de Ehrenfest es una cadena de Markov homogénea que representa una descripción matemática simplificada del proceso de difusión de gases o líquidos a través de una membrana. El modelo consiste de dos cajas A y B que contienen un total de N bolas. Seleccionamos al azar una de las N bolas y la colocamos en la otra caja. Sea X_n el número de bolas en la caja A después de n pasos. El espacio de estados es $S = \{0, 1, 2, \dots, N\}$, y las probabilidades de transición son:*

$$p_{i,i+1} = \frac{N-i}{N} \quad (\text{si seleccionamos una bola de la caja B}),$$

$$p_{i,i-1} = \frac{i}{N} \quad (\text{si seleccionamos una bola de la caja A}),$$

y $p_{ij} = 0$ para cualquier otro par (i, j) .

Ejemplo 1.14 (14). **La cadena de las horas del reloj.** Sea X_n la hora que marca un reloj después de n horas, donde las horas se representan como $S = \{0, 1, 2, \dots, 11\}$ (con 0 representando las 12 en punto). El proceso transiciona según la regla determinística:

$$X_{n+1} = (X_n + 1) \text{ mód } 12.$$

Esto significa que de cualquier hora i , el reloj avanza a la hora $i + 1$ (módulo 12) con probabilidad 1. Formalmente, las probabilidades de transición son:

$$p_{i,(i+1) \text{ mód } 12} = 1 \quad \text{para todo } i \in S,$$

y $p_{ij} = 0$ para cualquier otro par (i, j) .

La matriz de transición es:

$$P = \begin{pmatrix} 0 & 1 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & 0 & \cdots & 0 \end{pmatrix},$$

donde cada fila contiene exactamente un 1 (en la posición correspondiente a la siguiente hora) y ceros en todas partes.

Este es un ejemplo de cadena de Markov con estructura cíclica. Si el reloj comienza en las 3 en punto ($X_0 = 3$), después de 1 hora marca las 4 ($X_1 = 4$), después de 2 horas marca las 5 ($X_2 = 5$), y después de 12 horas regresa a las 3 ($X_{12} = 3$). De manera general, $X_n = (X_0 + n) \text{ mód } 12$.

Aunque el proceso es determinístico (no hay aleatoriedad en las transiciones), sigue siendo una cadena de Markov válida: el futuro depende únicamente del estado presente, no del pasado.

Para aumentar nuestro entendimiento de la propiedad de Markov, probaremos la siguiente proposición, que ayuda en la interpretación del futuro independiente del pasado dado el presente.

Proposición 1.4. Sea X una cadena de Markov homogénea (π, P) , con espacio de estados S , $i, j, k \in S$ y $0 \leq m \leq n - 1$. Se tiene que

$$\mathbb{P}(X_{n+1} = j | X_n = i, X_m = k) = \mathbb{P}(X_{n+1} = j | X_n = i).$$

1.6. Probabilidades de Transición en n Pasos

Hasta ahora hemos estudiado las probabilidades de transición de un paso, definidas como $p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i)$. Sin embargo, en muchas aplicaciones es fundamental conocer la probabilidad de que la cadena pase del estado i al estado j transcurridos exactamente n pasos, independientemente del instante inicial.

Definición 1.4. Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov homogénea con espacio de estados S . Definimos la **probabilidad de transición en n pasos** como:

$$p_{ij}^{(n)} = \mathbb{P}(X_{m+n} = j \mid X_m = i),$$

para cualesquiera $i, j \in S$ y $m, n \in \mathbb{N}$. La homogeneidad de la cadena garantiza que esta probabilidad es independiente del instante inicial m .

Observación 1.5. Por supuesto, para $n = 1$, recuperamos las probabilidades de transición de un paso:

$$p_{ij}^{(1)} = p_{ij}.$$

Asimismo, para $n = 0$, se define:

$$p_{ij}^{(0)} = \begin{cases} 1 & \text{si } i = j, \\ 0 & \text{si } i \neq j. \end{cases}$$

Esta es la matriz identidad, lo que tiene sentido: sin dar ningún paso, la cadena permanece en su estado actual con certeza.

Cuando el espacio de estados es finito, estas probabilidades pueden organizarse en una **matriz de transición en n pasos**:

$$P^{(n)} = (p_{ij}^{(n)})_{i,j \in S},$$

donde $P^{(1)} = P$ es la matriz de transición estándar y $P^{(0)} = I$ es la matriz identidad.

Ejemplo 1.15 (15). Consideremos la cadena de Markov del Ejemplo 12 con matriz de transición:

$$P = \begin{pmatrix} 0,5 & 0,3 & 0,2 \\ 0,1 & 0,6 & 0,3 \\ 0,2 & 0,2 & 0,6 \end{pmatrix}.$$

¿Cuál es la probabilidad de que la cadena transite del estado 1 al estado 2 en exactamente 2 pasos? Esta es la cantidad $p_{1,2}^{(2)}$. Para calcularla, podemos identificar todos los caminos de longitud 2 que comienzan en el estado 1 y terminan en el estado 2:

- Camino $1 \rightarrow 1 \rightarrow 2$: Probabilidad $p_{1,1} \cdot p_{1,2} = 0,5 \times 0,3 = 0,15$.
- Camino $1 \rightarrow 2 \rightarrow 2$: Probabilidad $p_{1,2} \cdot p_{2,2} = 0,3 \times 0,6 = 0,18$.
- Camino $1 \rightarrow 3 \rightarrow 2$: Probabilidad $p_{1,3} \cdot p_{3,2} = 0,2 \times 0,2 = 0,04$.

Por lo tanto:

$$p_{1,2}^{(2)} = 0,15 + 0,18 + 0,04 = 0,37.$$

Alternativamente, podemos calcular $P^{(2)} = P \cdot P = P^2$:

$$P^2 = \begin{pmatrix} 0,5 & 0,3 & 0,2 \\ 0,1 & 0,6 & 0,3 \\ 0,2 & 0,2 & 0,6 \end{pmatrix} \begin{pmatrix} 0,5 & 0,3 & 0,2 \\ 0,1 & 0,6 & 0,3 \\ 0,2 & 0,2 & 0,6 \end{pmatrix}.$$

El elemento $(1,2)$ de P^2 es:

$$(P^2)_{1,2} = 0,5 \times 0,3 + 0,3 \times 0,6 + 0,2 \times 0,2 = 0,15 + 0,18 + 0,04 = 0,37,$$

que coincide con nuestro cálculo anterior.

La Ecuación de Chapman-Kolmogorov

La ecuación de Chapman-Kolmogorov es una relación fundamental que conecta probabilidades de transición en diferentes números de pasos. Esta ecuación expresa una intuición natural: para ir del estado i al estado j en $n + m$ pasos, necesariamente pasamos por algún estado intermedio k después de los primeros n pasos.

[Ecuación de Chapman-Kolmogorov] Sea $\{X_n : n \in \mathbb{N}\}$ una cadena de Markov homogénea con espacio de estados S . Entonces, para cualesquiera enteros $n, m \geq 0$ y estados $i, j \in S$:

$$p_{ij}^{(n+m)} = \sum_{k \in S} p_{ik}^{(n)} \cdot p_{kj}^{(m)}.$$

En notación matricial:

$$P^{(n+m)} = P^{(n)} \cdot P^{(m)},$$

donde el producto es el producto usual de matrices.

Demostración. Demostraremos la ecuación utilizando la ley de probabilidad total y la propiedad de Markov.

Sean $n, m \geq 0$ y consideremos los estados $i, j \in S$. Por definición:

$$p_{ij}^{(n+m)} = \mathbb{P}(X_{n+m} = j \mid X_0 = i).$$

Condicionamos sobre el estado de la cadena después de n pasos, X_n . Por la ley de probabilidad total:

$$\mathbb{P}(X_{n+m} = j \mid X_0 = i) = \sum_{k \in S} \mathbb{P}(X_{n+m} = j \mid X_n = k, X_0 = i) \cdot \mathbb{P}(X_n = k \mid X_0 = i).$$

Ahora aplicamos la propiedad de Markov (Definición de cadena de Markov). Dado que la cadena es Markoviana y el estamos en el estado $X_n = k$, el futuro (desde el tiempo n en adelante) es independiente del pasado (antes del tiempo n). Específicamente:

$$\mathbb{P}(X_{n+m} = j \mid X_n = k, X_0 = i) = \mathbb{P}(X_{n+m} = j \mid X_n = k).$$

Por lo tanto:

$$p_{ij}^{(n+m)} = \sum_{k \in S} \mathbb{P}(X_{n+m} = j \mid X_n = k) \cdot \mathbb{P}(X_n = k \mid X_0 = i).$$

Reconocemos en esta expresión:

$$\mathbb{P}(X_{n+m} = j \mid X_n = k) = \mathbb{P}(X_m = j \mid X_0 = k) = p_{kj}^{(m)},$$

y

$$\mathbb{P}(X_n = k \mid X_0 = i) = p_{ik}^{(n)},$$

por la homogeneidad de la cadena. Por lo tanto:

$$p_{ij}^{(n+m)} = \sum_{k \in S} p_{ik}^{(n)} \cdot p_{kj}^{(m)},$$

que es exactamente la ecuación de Chapman-Kolmogorov.

En forma matricial, esta ecuación correspond a la multiplicación de matrices, es decir, $P^{(n+m)} = P^{(n)} \cdot P^{(m)}$. $\square$

Observación 1.6. *La ecuación de Chapman-Kolmogorov es fundamental porque implica que:*

$$P^{(n)} = \underbrace{P \times P \times \cdots \times P}_{n \text{ veces}} = P^n,$$

es decir, la matriz de transición en n pasos es simplemente la n -ésima potencia de la matriz de transición de un paso P . Esta es una consecuencia inmediata de la ecuación de Chapman-Kolmogorov aplicada recursivamente:

$$P^{(n)} = P^{(n-1+1)} = P^{(n-1)} \cdot P^{(1)} = P^{(n-1)} \cdot P.$$

Por inducción, obtenemos $P^{(n)} = P^n$.

Ejemplo 1.16 (16). *Retomemos la cadena de Markov del Ejemplo 12. Queremos calcular $p_{1,2}^{(3)}$, la probabilidad de ir del estado 1 al estado 2 en exactamente 3 pasos.*

Por la ecuación de Chapman-Kolmogorov con $n = 2$ y $m = 1$:

$$p_{1,2}^{(3)} = \sum_{k=1}^3 p_{1,k}^{(2)} \cdot p_{k,2}^{(1)}.$$

Primero necesitamos $P^{(2)} = P^2$. Ya calculamos este en el Ejemplo 15:

$$P^2 = \begin{pmatrix} 0,29 + 0,11 & 0,36 & 0,35 \\ \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot \end{pmatrix} \quad (\text{mostramos solo la fila relevante con detalle}).$$

Calculemos P^2 completamente. El elemento (i, j) de P^2 es $\sum_k p_{ik}p_{kj}$. Después del cálculo:

$$\begin{aligned} P^2 &= \begin{pmatrix} 0,5 \cdot 0,5 + 0,3 \cdot 0,1 + 0,2 \cdot 0,2 & 0,5 \cdot 0,3 + 0,3 \cdot 0,6 + 0,2 \cdot 0,2 & 0,5 \cdot 0,2 + 0,3 \cdot 0,3 + 0,2 \cdot 0,6 \\ 0,1 \cdot 0,5 + 0,6 \cdot 0,1 + 0,3 \cdot 0,2 & 0,1 \cdot 0,3 + 0,6 \cdot 0,6 + 0,3 \cdot 0,2 & 0,1 \cdot 0,2 + 0,6 \cdot 0,3 + 0,3 \cdot 0,6 \\ 0,2 \cdot 0,5 + 0,2 \cdot 0,1 + 0,6 \cdot 0,2 & 0,2 \cdot 0,3 + 0,2 \cdot 0,6 + 0,6 \cdot 0,2 & 0,2 \cdot 0,2 + 0,2 \cdot 0,3 + 0,6 \cdot 0,6 \end{pmatrix} \\ &= \begin{pmatrix} 0,25 + 0,03 + 0,04 & 0,15 + 0,18 + 0,04 & 0,10 + 0,09 + 0,12 \\ 0,05 + 0,06 + 0,06 & 0,03 + 0,36 + 0,06 & 0,02 + 0,18 + 0,18 \\ 0,10 + 0,02 + 0,12 & 0,06 + 0,12 + 0,12 & 0,04 + 0,06 + 0,36 \end{pmatrix} \\ &= \begin{pmatrix} 0,32 & 0,37 & 0,31 \\ 0,17 & 0,45 & 0,38 \\ 0,24 & 0,30 & 0,46 \end{pmatrix}. \end{aligned}$$

Ahora aplicamos Chapman-Kolmogorov:

$$p_{1,2}^{(3)} = p_{1,1}^{(2)} \cdot p_{1,2} + p_{1,2}^{(2)} \cdot p_{2,2} + p_{1,3}^{(2)} \cdot p_{3,2}$$

$$= 0,32 \times 0,3 + 0,37 \times 0,6 + 0,31 \times 0,2 = 0,096 + 0,222 + 0,062 = 0,380.$$

Alternativamente, podemos calcular $P^3 = P^2 \times P$ y leer el elemento $(1, 2)$.

Observación 1.7. La ecuación de Chapman-Kolmogorov no es únicamente un resultado teórico interesante; tiene profundas implicaciones prácticas. Al expresar $P^{(n)} = P^n$, nos proporciona un algoritmo eficiente (usando exponenciación rápida de matrices) para calcular probabilidades de transición en un gran número de pasos sin necesidad de enumerar todos los caminos posibles. Esto es especialmente relevante en aplicaciones computacionales donde frecuentemente nos interesa el comportamiento a largo plazo de cadenas de Markov.